

Exploratory Data Analysis of the Numerai Signals V1 Dataset

Numerai Comunity Tokyo Meetup 2024 7/20



NUMERAI

habakan

Profile

habakan


Software Engineer

Account

- Twitter: @habakan_f
- <https://numer.ai/habakan>



HABAKAN



NUMERAI

Numerai Signals V1のEDAをした

データは参加者で用意することがメインだったNumerai Signalsにおいて
2024/2にStarter featuresのデータセットV1がリリースされた

<https://forum.numer.ai/t/signals-v1-data-release/7050>

Numerai main tournament datasetと組み合わせながら
2つのデータセットの一致点、相違点を中心に分析した

背景: Main TournamentのPFが厳しくなった

Main Tournamentでモデリングを Stakeし続け話す内容がなくなった



Numerai Meetup tokyo 2023

PCAを利用したモデルポートフォリオを
構築するが儚く散る

2021年
Numerai参加開始



現在
一部をそのまま放置

2022年

Main Tournament
のメインモデル構築

2023年

そのままStakeし
TCも乗り切る


			
Your Season 2022 Status			
TC Rank	CORR Rank	Final Tier	
17	69	Expert	
of 818	of 818	Top 100 in CORR or TC	
Expert			
			
Your Season 2023 Status			
TC Rank	CORR Rank	Final Tier	
47	90	Expert	
of 738	of 738	Top 100 in CORR or TC	
Expert			
« View 2022 status			

背景: Main TournamentのPFが厳しくなった

TC時代に良かったモデルが MMC以降一部のモデルが厳しくなる


MMC Score

Cumulative stake-weighted-average MMC score of all models over the past 1 year vs Numerai benchmark models



CORR Score


Cumulative stake-weighted-average CORR score of all models over the past 1 year vs Numerai benchmark models




背景: Main TournamentのPFが厳しくなった

TC時代に良かったモデルが MMC以降一部のモデルが厳しくなる

Compare Scores



PAYOUTS WILL BE BASED ON TC



モデルの一部がMMCが悪く
Stakeモデルを一部に変更

Numeraiのようなデータセットの構築への興味


MMC以外にも考えさせられる出来事がありました

- ・ **My Numerai recent return < My wife trading recent return**
- ・ JQuantsAPIでLSモデルを作るが、線形モデルで毎回学習結果が変わる
 - ・ 嫁に「**お前のデータの RoEなんかおかしくね？**」と言われ
API経由で毎回収集し直している財務データが変わることに気づく

Numeraiのようなデータセットの構築への興味

MMC以外にも考えさせられる出来事がありました

- ・ **My Numerai recent return < My wife trading recent return**
- ・ JQuantsAPIでLSモデルを作るが、線形モデルで毎回学習結果が変わる
 - ・ 嫁に「**お前のデータの RoEなんかおかしくね？**」と言われ
API経由で毎回収集し直している財務データが変わることに気づく



- ・ 株式データのデータ基盤として正しいデータ提供とは何か考え始める
- ・ Main Tournamentの匿名性データで逃げてきた要素を
Signals V1を触りながらキャッチアップしたい
- ・ ~~売り切る前に下落してしまっているNMRをなんとかしたい~~

分析方針

Main Tournamentのデータセットとの違いを意識し データセットの構造を理解する

今まで慣れてきたMain Tournamentとの差分を主に分析する
その上で情報量の多いSignalsの場合どのような分析ができるかを
簡易的に検証する

※Main Tournamentのデータセットはv4.3を利用

分析内容

- ・データ構造でのMain, Signalsのデータセット比較
- ・特徴量の分析
- ・特徴量とTargetの分析

Numerai Signals

参加者が所持しているデータソースからシグナルを提出する

Introduction

While the [Numerai Tournament](#) provides free data, [Numerai Signals](#) asks you to bring your own data - your own unique signal. A signal in the stock market is a feed of information. It is numerical data about stocks that can be used by quantitative hedge funds like Numerai. These feeds of information are used to model the stock market and construct portfolios (collections of stock holdings).

Examples of stock market signals include:

- [Fundamental signals](#) (P/E ratio, dividend yield, analyst ratings)
- [Technical signals](#) (MACD, RSI, MFI)
- [Alternative data signals](#) (credit card transactions, satellite images, social media sentiment)
- [Blended signals](#) (Barra risk factors, Fama French factors)

If you're a data provider you can submit unique features directly as signals. If you're a data scientist, you can model unique data to submit predictions as signals. Signals are then scored against our targets and other submitted signals. Signals can be staked with the NMR cryptocurrency to earn (or burn) NMR based on performance.

Numerai Signals is one part of the Numerai master plan to build the world's last hedge fund. Read the [Medium Post](#) and watch [the short film](#) to learn more about how it all fits together.



ticker	signal
AAPL US	0.5488135039273250
TSLA US	0.7151893663724200
EMG LN	0.6027633760716440
2638 HK	0.5448831829968970
MOH GA	0.4236547993389050

データ構造での Main, Signalsのデータセット比較

Main TournamentとSignalsの比較

id	era	feature1	...	feature310	target
n2b2e3dd163cb422	era1	0.75	...	0.00	0.25
n177021a571c94c8	era1	1.00	...	0.25	0.75
n7830fa4c0cd8466	era1	0.25	...	1.00	0.00
nc584a184cee941b	era1	0.25	...	0.00	1.00
nc5ab8667901946a	era1	0.75	...	0.25	0.25
n84e624e4714a7ca	era1	0.00	...	0.75	1.00

	Main Tournament (Rain)	Signals V1 Dataset
データ区分	Train, Valid, Live	Train, Valid, Live
特徴量数	2276	21
target数	48	22
Ticker情報	匿名化されている	匿名化されていない
日付変数	era	date
trainデータ数	2420521	2164693
validation データ数	2794929	3023759


ポイント: Ticker, eraの構造自体は似ている

データ数は異なるが、era数は一致している

	Main Tournament (Rain)	Signals V1 Dataset
trainデータ数	2420521	2164693
validation データ数	2794929	3023759
総データ数	5215450	5188452
train era数	574	522
validation era数	550	602
総era数	1124	1124


ポイント: Ticker, eraの構造自体は似ている

EraごとのTicker数の推移は似ている



国別の割合推移

データセットは提供されているが



Signals V1の特徴量について

Signals V1の特徴量

24個の特徴量で構成されており、グループが存在

テクニカル以外の
ファクターも含まれている


feature_adv_20d_factor
feature_beta_factor
feature_book_to_price_factor
feature_country
feature_dividend_yield_factor
feature_earnings_yield_factor
feature_exchange_code
feature_growth_factor
feature_impact_cost_factor
feature_market_cap_factor
feature_momentum_12w_factor
feature_momentum_26w_factor
feature_momentum_52w_factor
feature_momentum_52w_less_4w_factor
feature_ppo_60d_130d_country_ranknorm
feature_ppo_60d_90d_country_ranknorm
feature_price_factor
feature_rsi_130d_country_ranknorm
feature_rsi_60d_country_ranknorm
feature_rsi_90d_country_ranknorm
feature_trix_130d_country_ranknorm
feature_trix_60d_country_ranknorm
feature_value_factor
feature_volatility_factor

語尾にfactorがついているものはtargetに対してneutralなリスクファクター

ranknormは国ごとに標準化

ポイント: featureに欠損が含まれている


そのままTargetとのCorrの累積を見ようとし、欠損を発見



ポイント: featureに欠損が含まれている


古いEraが欠損が多いFactorが存在

各特徴量のEraごとの欠損率



ポイント: featureは分位化されていない


単峰でほぼ標準化はされているものの
Main Tournamentのように binningはされていない



ポイント: featureに欠損が含まれている



欠損の相関をみると、グループごとに欠損のタイミングが似ている

Eraごとの欠損率の相関ヒートマップ





Tickerごとの特徴量分析

上位銘柄10件で銘柄ごとの分布を確認
factor系はTickerごとに分布が異なる





Tickerごとの特徴量分析

上位銘柄10件で銘柄ごとの分布を確認
ranknorm系は分布が異なるわけではない



Tickerごとの特徴量分析


targetは標準化されている



特徴量とTargetの分析

Signals V1のTarget

24個の特徴量で構成されており、グループが存在



Signals V1のTarget

24個の特徴量で構成されており、グループが存在

リスクファクター？
を直交化したtarget

target
target_raw_return_20
target_raw_return_60
target_factor_neutral_20
target_factor_neutral_60
target_factor_feat_neutral_20
target_factor_feat_neutral_60
target_camille_20
target_camille_60
target_sydney_20
target_sydney_60
target_irina_20
target_irina_60
target_alexandra_20
target_alexandra_60
target_colleen_20
target_colleen_60
target_jean_20
target_jean_60
target_eleven_4
target_eleven_20
target_eleven_60


targetはtarget_factor_feat_neutral_20

Main Tournamentのfeatures
をさらに直交化

eleven系は旧target
e.g. target_eleven_4 = target_4d

Corr Cumsum plot: target

Targetとの相関を cumsum でplot
ranknorm系がsharpが高い




Corr Sharpe 上位3ファクター

	Corr Sharpe
feature_ppo_60d_130d_country_ranknorm	0.2986
feature_ppo_60d_90d_country_ranknorm	0.2918
feature_rsi_90d_country_ranknorm	0.2839

Corr Cumsum plot: target_raw_return_20

データセットは提供されているが




Corr Sharpe上位3ファクター

	Corr Sharpe
feature_earnings_yield_factor	0.2648
feature_value_factor	0.2638
feature_dividend_yield_factor	0.2159

Corr Cumsum plot: target_factor_neutral_20

疑問: Factor Neutralなら無相関になるのではないか？




Corr Sharpe上位3ファクター

	Corr Sharpe
feature_value_factor	0.5263
feature_earnings_yield_factor	0.4348
feature_book_to_price_factor	0.3624

Corr Cumsum plot: target_feat_factor_neutral_20

疑問: Main Tournamentに含まれているFeatなら無相関になるのでは?
→Factor featureはMain Tournamentのデータに含まれていない?



Corr Sharpe 上位3ファクター



	Corr Sharpe
feature_adv_20d_factor	0.2322
feature_growth_factor	0.1396
feature_price_factor	0.1153

まとめ

- Main TournamentのEra期間はユニバースは大枠一致している異なる点
 - Train, Validation期間は比率が異なっている
 - 欠損値が存在する
 - 欠損は古い期間に多いが、特徴量のグループごとに欠損は相関する
- SignalsではTickerごとに特徴量の分析ができる
 - Tickerごとに分布の異なる特徴量も存在する
- Targetと特徴量の関係を分析し、直交化の方法を分析・考察した
 - 線形ではranknorm系がtrainだと強い
 - factor系特徴量とtarget_factor_neutralizedで直交化されている
 - factorはおそらく一緒ではない？
 - factor系はMain Tournamentの直交化特徴量には含まれていない？


おまけ Main Tournamentの特徴量特定(失敗)

Signals V1の特徴量がMain Tournamentに含まれているか検証
共分散行列が一致するような Main特徴量の組み合わせを探索
ただ、解が多いためかあまりうまくいっていない



おまけ Main Tournament V5での適応

Main Tournamentのv5は特徴量などは同じだが Ticker数が異なる
既存と比較してユニバースを拡張している
Signalsもユニバースは拡張される？



今後の方向性

- ・分位化や欠損値補完の扱いはどうするか？
中央値処理で大丈夫か？
- ・y-finance, JQuantsなどの組み合わせたらどうなるか？
同じfactorを作れるか？
アンサンブルで向上するか？
- ・ユニバースを日本株に絞ったときどうなるか？
JQusantsで作ったモデルのみだと予測は落ちるのか？